Машинное обучение в экономике

Введение в машинное обучение

Потанин Богдан Станиславович

доцент, старший научный сотрудник, кандидат экономических наук

2026-2027

Машинное обучение

Определение

- Машинное обучение возникает во второй половине 20-го века на стыке множества дисциплин, таких как математическая статистика, искусственный интеллект и оптимизация.
- **Проблема разграничения** — как и множество других дисциплин, таких как эконометрика и интеллектуальный анализ данных (data mining), машинное обучение используется для анализа данных.
- **Ключевое отличие** — машинное обучение концентрируется преимущественно на получении точных прогнозов, в отличие, например, от эконометрики, в которой основной упор делается на получении точных оценок параметров модели.
- Например, в машинном обучении мы можем преследовать цель спрогнозировать заработную плату, а в эконометрике — точно оценить параметры, характеризующие влияние образования на зарплату. В качестве таких параметров могут рассматриваться, например, регрессионный коэффициент при переменной, отражающей образование, или средний эффект воздействия.

История анализа данных

Ранние этапы анализа данных

- С древних времён люди собирали, систематизировали и анализировали данные.
- Например, в Древнем Египте и Древнем Риме собирались данные об урожае и налогах, которые впоследствии использовались в административных целях.
- В Вавилоне собирались астрономические данные, которые применялись для прогнозирования движения планет.
- В 17 веке возникают методы анализа социально-демографических данных. Исследователи начинают искать закономерности в этих данных и делать содержательные выводы.
- Пионером в данной области стал Джон Граунт, который проанализировал таблицы смертности в Лондоне, регулярно публиковавшиеся с 1603 года и содержавшие информацию о количестве смертей и их причинах, а также возрасте и поле умерших.
- В частности, Джон Граунт обратил внимание на то, что мужчин рождается и умирает больше, чем женщин, а также оценил вероятность дожить до определённого возраста как долю оставшихся в живых к соответствующему возрасту.

История анализа данных

Теория вероятностей и математическая статистика

- **Проблема** — на ранних этапах анализ данных представлял собой множество разрозненных, преимущественно эвристических методов, решавших частные задачи и не объединённых общей теоретической базой.
- Без теоретической базы сложно развивать методы, изучать их эффективность, сравнивать эти методы между собой и обосновывать их применимость к той или иной задаче.
- **Решение** — использование теории вероятностей, а впоследствии и сформировавшейся на её базе математической статистики, в качестве теоретической базы для методов анализа данных.
- Математическая статистика стала активно развиваться со второй половины 17 века, в особенности после публикации доказательства закона больших чисел для бернуллиевских случайных величин Яковом Бернулли в 1713 году.
- Например, в начале 19 века Адриен-Мари Лежандр (1805 год) и Карл Фридрих Гаусс (1795 или 1809 год) предложили метод наименьших квадратов (МНК) и обосновали его с точки зрения теории вероятностей. Кроме того, в 1810 году Пьер-Симон Лаплас использовал доказанную им центральную предельную теорему для обоснования асимптотических свойств МНК-оценок.
- С начала 20-го века активно развивается теория построения доверительных интервалов и теория тестирования гипотез. В результате обоснование метода анализа данных с точки зрения теории вероятностей позволяет подключить к нему эти полезные инструменты.

История анализа данных

Возникновение эконометрики

- В 20-м веке математическая статистика начинает активно применяться для анализа экономических данных, в частности, оценивания параметров экономических моделей, в результате чего формируется эконометрика.
- Одними из ключевых основателей эконометрики были Ян Тинберген и Рагнар Фриш, получившие в 1969 году первую в истории Нобелевскую премию по экономике за создание прикладных динамических моделей анализа экономических процессов.
- Существенный вклад в развитие эконометрики внёс и Евгений Евгеньевич Слуцкий, применявший теорию случайных процессов для анализа макроэкономических данных. Также он внёс серьёзный вклад в микроэкономику (уравнение Слуцкого: эффект замещения и эффект дохода) и теорию вероятностей (теорема Слуцкого).

История анализа данных

Развитие эконометрики

- Экономисты традиционно развивают эконометрику не только за счёт применения математической статистики, но и внося **вклад** в её развитие. Так, например, нобелевский лауреат по экономике Ларс Петер Хансен предложил обобщённый метод моментов (GMM) и изучил его свойства. Также экономист Филип Грин Райт предложил метод инструментальных переменных.
- **Особенность эконометрики** — направление вклада в математическую статистику часто мотивируется содержательными экономическими соображениями и теоретическими моделями. Например, модель Роя мотивировала развитие статистических методов анализа усечённых и цензурированных данных. Наиболее известными из этих методов являются метод Тобина и метод Хекмана.
- Популярность эконометрики и тесная связь её развития с математической статистикой, вероятно, обусловили то, что применение математической статистики в других социальных науках, таких как политология, психология и социология, также часто именуется эконометрикой.

История анализа данных

Искусственный интеллект

- Исследования в области искусственного интеллекта (ИИ / AI) преследовали цель создания компьютеров, способных решать присущие человеку задачи, такие как распознавание изображений, игра в шахматы и общение.
- На ранних этапах искусственный интеллект часто опирался на заранее запрограммированные человеком правила. Например, многие программы для игры в шахматы использовали различные алгоритмы, опиравшиеся на теорию игр.
- **Проблема** — искусственный интеллект опирается на заранее детерминированные человеком правила, что ограничивает его способность адаптироваться к новой информации и может потребовать больших временных затрат на разработку новых алгоритмов.
- **Решение** — обучить компьютер решать задачи с помощью анализа данных. Например, на основании анализа тысяч игр можно обучить компьютер играть в шахматы.
- Машинное обучение занимается созданием систем искусственного интеллекта, обучающихся на данных.

Сферы применения машинного обучения

Искусственный интеллект

- Сфера применения машинного обучения в задачах искусственного интеллекта крайне обширна, поэтому перечислим лишь некоторые примеры.
- **Компьютерные игры** — поведение неигровых персонажей (NPC), процедурная генерация локаций (пещер, планет и т. д.), адаптация условий игры, например, параметров сложности в зависимости от результативности игрока.
- **Музыка** — замена голоса одного певца на другого (AI cover), генерация музыки.
- **Видео** — замена изображения одного человека на другого (deepfake), генерация видео, анализ видео, например, для выявления преступлений.
- **Текст** — генерация текстов и оценивание их тональности (весёлый / грустный, позитивный / негативный).
- **Изображения** — генерация изображений, анализ изображений, например, для определения факта наличия на них определённых объектов (людей, животных и т. д.).

Сферы применения машинного обучения

Прогнозирование в экономических задачах

- С использованием машинного обучения можно прогнозировать дефолты по кредитам, продажи, уход клиента, переход по ссылке, цены акций и т. д.
- Например, прогноз вероятности дефолта можно использовать при принятии решения о выдаче кредита или о процентной ставке по нему, а также для того, чтобы заранее выявить клиентов, находящихся в группе риска, и принять соответствующие меры, например, по реструктуризации кредита.
- Особую роль машинное обучение играет в построении рекомендательных систем (фильмы, музыка, товары и т. д.). С учётом того, что эти системы охватывают крайне большое число пользователей, даже небольшое повышение точности прогнозов рекомендательных систем может привести к крайне существенному (в абсолютной величине) росту прибыли фирмы.
- Например, если ваша система за день показывает 1 миллиард рекомендаций и каждая успешная рекомендация приносит вам 1 цент, то при прочих равных повышение вероятности успешной рекомендации даже лишь на 0.01 принесёт фирме дополнительные $10^9 \cdot 0.01 \cdot 0.01 = 10^5 = 100000$ долларов.

Сферы применения машинного обучения

Задачи экономиста

- Непосредственное получение точных прогнозов является задачей специалиста в области машинного обучения, в качестве которого может выступать в том числе и экономист.
- Помимо получения прогнозов, экономисты также решают ряд специфических для их профессии задач, а именно определяют:
  - **Что нужно прогнозировать**. Например, вероятность дефолта в зависимости от характеристик заёмщика (образования, дохода и т. д.).
  - **Как использовать прогнозы**. Например, исходя из критерия максимизации ожидаемой прибыли, определить наибольшую вероятность дефолта, при которой банк готов дать клиенту ипотечный кредит.

Сферы применения машинного обучения

Эконометрика

- В эконометрике машинное обучение часто используется для повышения точности оценок вспомогательных параметров (nuisance parameters), которые сами по себе не подлежат содержательной интерпретации, но используются для оценивания других параметров, имеющих экономический смысл.
- Например, в задаче оценивания эффектов воздействия (ATE, ATET, CATE и т. д.) машинное обучение используется для оценивания условных математических ожиданий (обычно не интерпретируются), которые впоследствии применяются для оценивания эффектов воздействия (интерпретируются).
- Также машинное обучение активно применяется для получения вспомогательных переменных для эконометрического анализа.
- Например, исследователь может проанализировать тональность новостей и, сформировав соответствующую переменную, использовать её для прогнозирования цен акций или инфляции.

Информация о курсе

Цели и структура курса

- **Техническая цель** — научиться применять методы машинного обучения для:
  - прогнозирования социально-экономических показателей.
  - эконометрического анализа, в частности, оценивания эффектов воздействия и создания вспомогательных переменных.
- **Содержательная цель** — научиться использовать полученные прогнозы и оценки эффектов воздействия для решения экономических задач.
- Курс содержит два основных блока:
  - использование методов машинного обучения для получения прогнозов, оценка их качества и использование в экономических задачах.
  - применение методов машинного обучения в эконометрическом анализе.
- Основная информация, включая презентации лекций и материалы семинаров, публикуется на вики-страничке курса:

http://wiki.cs.hse.ru/Машинное_обучение_в_экономических_исследованиях_2026-2027

Информация о курсе

Оценка

- Формула оценки за курс:

$$\text{Оценка} = 0.1 \cdot \text{Активность} + 0.01 \cdot \text{Домашнее задание 1} + \\ + 0.29 \cdot \text{Домашнее задание 2} + 0.6 \cdot \text{Экзамен}$$

- **Домашнее задание** — выполняется в группах до 3-х человек и концентрируется на оценивании эффектов воздействия с помощью методов машинного обучения.
- **Активность** — активность на лекциях и семинарах.
- **Экзамен** — задачи и открытые вопросы по материалам лекций и семинаров.
- **Творческий акцент** — домашнее задание выполняется на самостоятельно симулированных (созданных) данных, генерация которых сопровождается содержательным обоснованием предполагаемого процесса генерации данных.
- **Округление** — промежуточные оценки не округляются. Округляется только итоговая оценка за курс по обычным правилам. Например, 3.5 округляется до 4, а 3.49 — до 3.