

Задача 1

К вам обратился музыкант, в произведениях которого используются голоса животных. Он хочет научиться прогнозировать, станет ли его произведение хитом (переменная Хит_i), в зависимости от наличия в нем звуков мяуканья кошки (переменная Мяу_i), лая собаки (переменная Гав_i) и карканья вороны (переменная Кар_i). У вас имеется следующая **обучающая выборка**.

Хит_i	1	1	1	0	0	0
Мяу_i	1	1	0	0	1	0
Гав_i	1	0	0	1	0	0
Кар_i	1	1	0	0	0	1

С каждого хита музыкант зарабатывает 10 миллионов рублей, а с других произведений – лишь 1 миллион рублей. Также, независимо от качества произведения, музыкант всегда может за 5 миллионов рублей заказать услуги у пиар агентства, которое гарантирует, что произведение станет хитом. Вы прогнозируете, что произведение станет хитом, если соответствующая условная вероятность оказывается не меньше 0.2. При этом музыкант полностью доверяет вашим прогнозам. Для прогнозирования используется байесовская сеть, в которой переменная Хит_i является родителем для всех остальных переменных. Также, переменная Кар_i является ребенком переменной Гав_i .

Наконец, у вас имеется **тестовая** выборка из двух произведений. В первом из них использовалось лишь мяуканье кошки и оно стало хитом. Во втором произведении звучало лишь карканье вороны и оно хитом, к сожалению, не стало.

1. Проиллюстрируйте рассматриваемую байесовскую сеть с помощью графа.
2. Определите цены каждого типа прогнозов и рассчитайте прибыль на тестовой выборке.
3. Определите, изменит ли свою стратегию в отношении заказа услуг пиар агентства нейтральный к риску музыкант, который доверяет не непосредственно вашим прогнозам, а оценкам условных вероятностей. Оцените прибыль прогнозов на тестовой выборке при соответствующей стратегии.
4. Используя обученную байесовскую сеть методом S-learner оцените условный средний эффект воздействия мяуканья кота на становление хитом песни, в которой нет ни лая собаки, ни карканья вороны.

Задача 2

Вы работаете аналитиком в фирме, занимающейся производством фильмов. Вам поручили изучить, как факт наличия звезды (крайне популярного актера) в фильме влияет на его рейтинг (измеряется в непрерывной шкале от 0 до 10). Для этого вы используете следующие данные.

Рейтинг _{<i>i</i>}	10	4
Звезда _{<i>i</i>}	1	0
Бюджет _{<i>i</i>}	9	5

Для оценивания математического ожидания рейтинга, условного на бюджет (в миллионах долларов) и факт наличия звезды, применяется нейронная сеть с 2 скрытыми слоями, в каждом из которых расположен 1 нейрон. Во всех случаях (включая выходной слой) применяется функция активации $h(s) = 5s$, константы (смещения) отсутствуют, функция потерь является квадратичной, изначально все веса равняются 0.2. Обучается только вес, с которым нейрон первого слоя входит в нейрон второго слоя. Для обучения используется один шаг алгоритма градиентного спуска со скоростью обучения $1/500$.

1. Нарисуйте используемую нейросеть и рассчитайте значение ее функции потерь при начальных значениях весов, усреднив функции потерь, посчитанные для каждого наблюдения.
2. С помощью двухчастной кросс-валидации оцените MAE нейросети, обучающейся в соответствии с описанным алгоритмом.
3. С помощью T-learner, основанного на описанной нейросети, для фильма бюджетом 10 миллионов долларов оцените условный средний эффект воздействия факта наличия звезды на рейтинг фильма.
4. Принцип обучения нейросети остается прежним, за тем исключением, что теперь вы также применяете Лассо регуляризацию со штрафом λ . Найдите минимальное значение штрафа λ , при котором оценка SATE в предыдущем пункте равняется нулю.

Задача №3

У вас имеется выборка из $n = 8$ наблюдений, характеризующих успешность стартапов в зависимости от наличия рекламной кампании и опытных членов команды, а также того, связан ли стартап с тематикой здоровья.

Успех	Реклама	Опыт	Здоровье
1	1	1	0
0	1	1	1
1	0	1	1
0	0	0	1
1	1	1	0
0	0	0	0
1	0	1	0
0	0	1	0

Вы обучаете решающее дерево глубины 2, прогнозирующее успех стартапа с помощью всех имеющихся в данных признаков (реклама, опыт и здоровье). В качестве критерия разбиения используется энтропия. Прогнозируется, что стартап окажется успешным, если условная вероятность этого события превышает 0.4.

Подсказка: вместо логарифма с основанием 2 эквивалентно использовать натуральный логарифм, необходимые значения которого указаны ниже:

$$\begin{aligned}
 \ln(1/8) &\approx -2.079 & \ln(2/8) &\approx -1.386 & \ln(3/8) &\approx -0.981 & \ln(4/8) &\approx -0.693 \\
 \ln(5/8) &\approx -0.470 & \ln(6/8) &\approx -0.288 & \ln(7/8) &\approx -0.134 & \ln(8/8) &= -0.000 \\
 \ln(1/6) &\approx -1.792 & \ln(2/6) &\approx -1.099 & \ln(4/6) &\approx -0.405 & \ln(5/6) &\approx -0.182 \\
 \ln(1/5) &\approx -1.609 & \ln(2/5) &\approx -0.916 & \ln(3/5) &\approx -0.511 & \ln(4/5) &= -0.223
 \end{aligned}$$

1. Изобразите обученное решающее дерево графически, в каждом листе указав долю успешных стартапов. Обязательно приведите в решении подробные расчеты, с помощью которых было построено дерево.
2. С использованием построенного решающего дерева для обучающей выборки запишите матрицу ошибок (confusion matrix) и рассчитайте F1-метрику.
3. Используя обученное ранее решающее дерево с помощью S-learner оцените средний эффект воздействия тематики здоровья на успех стартапа.